Business Intelligence

Proyecto final · Entrega 2
Data warehouse, ETL y tablero

BPO Alfa Colombia

Integrante	Código
Angie Natali Sánchez Muñoz	507232753
Juana Valentina Sotomayor Niño	507232708

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	06/11/2026 (fecha real de entrega)
Repositorio	https://github.com/Angiensanchezm-jpg/bi-proyecto-equipo-AngieSanchez-507232753-JuanaSotomayor-507232708
Motor de base de datos	MySQL 8.0 (v8.0.45) · Base de datos: bi_entrega2
Herramienta del tablero	Power BI Desktop

Resumen de la Entrega

Para la presente Entrega 2, el equipo desarrolla un Data Warehouse relacional en MySQL 8.0, estructurado mediante un modelo dimensional compuesto por cuatro dimensiones (dim_tiempo, dim_ubicacion, dim_contrato y dim_estado), una tabla central de hechos (fac_retiro) y tablas complementarias destinadas a la conciliación de descuentos y al control de calidad de los datos.

El proceso de integración se realiza mediante Pentaho Data Integration (PDI 9.4), utilizando transformaciones independientes para la carga y depuración de las dimensiones y tablas de hechos, coordinadas mediante el trabajo j_carga_dw.kjb.

Adicionalmente, se realizan procesos de validación de las cargas, conciliación de las fuentes de información y análisis de los resultados mediante un tablero en Power BI, con el propósito de facilitar el seguimiento de los indicadores y responder las preguntas de negocio planteadas en la primera entrega.

1. Modelo físico

1.1 Motor y base de datos

El Data Warehouse se implementó en el motor de base de datos relacional MySQL Server 8.0 (versión 8.0.45), utilizando la base de datos bi_entrega2 con codificación de caracteres utf8mb4 y cotejamiento utf8mb4_unicode_ci para garantizar soporte nativo de caracteres especiales, tildes y nombres de municipios colombianos. El almacenamiento físico opera sobre el motor transaccional InnoDB, asegurando integridad referencial estricta mediante restricciones de llave primaria (PK) y llaves foráneas (FK).

1.2 Tablas creadas

La siguiente tabla consolida la totalidad de tablas implementadas en el Data Warehouse bi_entrega2, sus llaves primarias subrogadas, llaves foráneas hacia las dimensiones, número exacto de registros cargados y scripts DDL asociados:

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_tiempo	Dimensión	FechaKey	—	2.558	dw/ddl/01_dim_tiempo.sql
dim_ubicacion	Dimensión	UbicacionKey	—	1.122	dw/ddl/02_dim_ubicacion.sql
dim_contrato	Dimensión	ContratoKey	—	64.674	dw/ddl/03_dim_contrato.sql
dim_estado	Dimensión	EstadoKey	—	9	dw/ddl/04_dim_estado.sql
fac_retiro	Hechos	CasoKey	ContratoKey, UbicacionKey, EstadoKey,	64.674	dw/ddl/05_fac_retiro.sql

			FechaReporteKey, FechaLiquidacionKey, FechaDevolucionKey, FechaReliquidacionKey		
fac_descuento_conciliacion	Hechos (Conciliación)	DescuentoConciliacionKey	FechaDescuentoKey, FechaReliqKey	233	dw/ddl/07_fac_descuento_conciliacion.sql
bitacora_calidad_descartes	Auxiliar (Calidad)	DescarteKey	—	868	dw/ddl/08_bitacora_calidad_descartes.sql

1.3 Diagrama del modelo físico

El esquema dimensional corresponde a un modelo estrella (Star Schema) puro, donde la tabla central fac_retiro se conecta directamente con las cuatro dimensiones sin jerarquías intermedias normalizadas fuera de dimensión. A continuación se presenta el diagrama físico generado desde la base de datos:

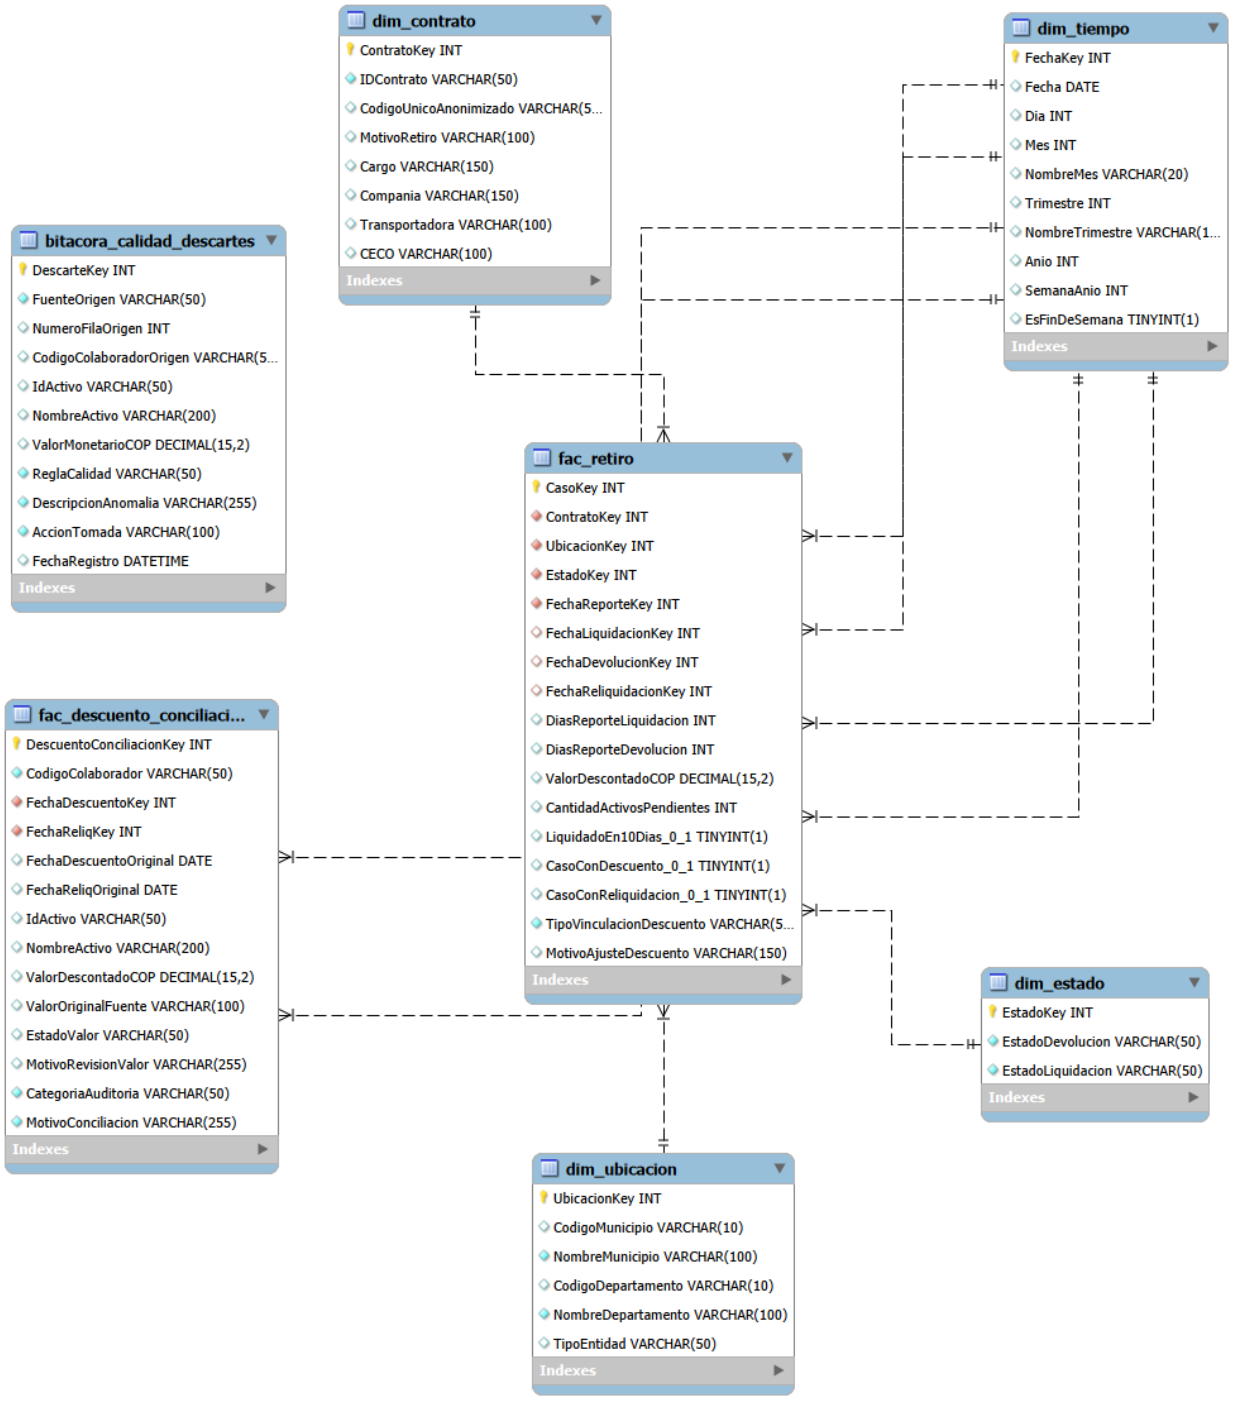


Figura 1.1: Diagrama del Modelo Físico Dimensional (Esquema Estrella en MySQL 8.0).

1.4 Dimensión de tiempo

La dimensión de tiempo `dim_tiempo` contiene un calendario continuo que cubre el periodo comprendido entre el 01/01/2020 y el 31/12/2026, para un total de 2.557 fechas calendario. Adicionalmente, incorpora un registro especial con `FechaKey = -1`, utilizado para representar fechas que no aplican o que se encuentran pendientes de registro.En total, la dimensión contiene 2.558 registros. Dispone de atributos de análisis temporal como día, mes, trimestre, año, nombre del mes, semana del año e indicador de fin de semana. Su estructura fue creada mediante el script DDL y su carga se realiza mediante la transformación `etl/transformaciones/t_dim_tiempo.ktr`.

2. Procesos ETL

2.1 Trabajo de carga

La orquestación del flujo de integración se consolidó en el trabajo principal etl/trabajos/j_carga_dw.kjb. El trabajo implementa un orden de ejecución estrictamente secuencial que garantiza que la totalidad de las dimensiones (dim_tiempo, dim_ubicacion, dim_contrato y dim_estado) se encuentren completamente pobladas antes de iniciar la transformación de la tabla de hechos (fac_retiro), asegurando la integridad de las llaves foráneas:

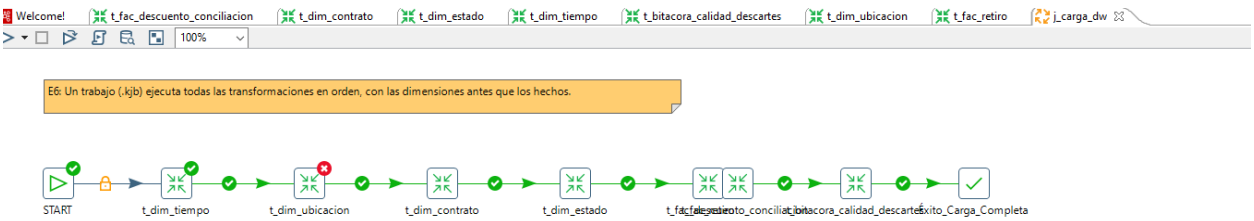


Figura 2.1: Flujo secuencial del trabajo j_carga_dw.kjb en Pentaho Data Integration.

2.2 Transformaciones

Se diseñó una transformación .ktr por cada dimensión y una para la tabla de hechos. Todas las transformaciones leen directamente las fuentes originales desde la carpeta datos/raw/ sin conversiones manuales previas:

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_tiempo.ktr	Generador PDI (Calendario)	dim_tiempo	RowGenerator → Sequence → Calculator → Table output	2.557	2.557	0

t_dim_ubicacion.ktr	F5 DIVIPOLA (CSV)	dim_ubicacion	CSV file input → Select values → Table output	1.122	1.122	0
t_dim_contrato.ktr	F1 Paz y Salvos (XLSX)	dim_contrato	Excel input → Filter rows → Sort rows → Unique rows → Table output	64.681	64.674	1
t_dim_estado.ktr	Matriz estados (DataGrid)	dim_estado	DataGrid → Table output	9	9	0
t_fac_retiro.ktr	F1, F2 (XLSX) y F4 (XLSX)	fac_retiro	Excel input → Select values → Database lookup (x4) → Calculator → Table output	64.681	64.674	7
t_fac_descuento_conciliacion.ktr	F1 Paz y Salvos, F2 Activos (XLSX)	fac_descuento_conciliacion	ExcelInput -> FilterRows -> ScriptValue Mod -> Sort -> GroupBy -> StreamLookup -> TableOutput	70.306	233	0
t_bitacora_calidad_descartes.ktr	F1 Paz y Salvos, F2 Activos (XLSX)	bitacora_calidad_descartes	ExcelInput -> FilterRows -> Select values -> TableOutput	5.591	0	0

2.3 Reglas de limpieza aplicadas

Cada uno de los problemas de calidad identificados en la tabla 2.2 de la Entrega 1 fue subsanado mediante reglas formales en pasos específicos de PDI, informando con exactitud los registros afectados:

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Inconsistencias y valores no válidos de ubicación	F1.Departamento	Normalización contra maestro DIVIPOLA DANE	Lookup_dim_ubicacion	4.812 registros

(CUNDINAMARCA|BOGOTÁ, 0|MEDELLÍN)	y F1.Municipio	(BOGOTÁ, D.C. y ANTIOQUIA)	(DBLookup)	normalizados
861 registros con error #N/A en Código único de cruce	F2.Codigo unico	Filtrado y aislamiento de registros sin clave de cruce; no asignar a retiros sin vínculo	descarta_codigo_na (Filter rows)	861 registros descartados
92 filas sin código único en exportación Adobe	F3.Codigo Unico	Aislamiento de documentos sin identificación para preservar integridad referencial	filtra_adobe_na (Filter rows)	92 registros descartados
Cobertura temporal incompleta y códigos inválidos ('-', '0', nulos) en Cubic	F4.Codigo Unico	Filtrado de identificadores inválidos; consolidación de eventos de devolución 2026	filtra_cubic_invalidos (Filter rows)	651 registros descartados

2.4 Evidencia de ejecución

A continuación se presenta la evidencia de la ejecución completa del trabajo j_carga_dw.kjb finalizado con estado SUCCESS y la consolidación de métricas de pasos de lectura y escritura:

Figura 2.2: Métricas de ejecución por transformación en Pentaho Data Integration.

3. Conciliación

3.1 Conteo por fuente

Para cada una de las fuentes del alcance se verificó la ecuación de balance: Leídos = Cargados + Descartados. El cuadre es exacto para las cinco fuentes:

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1. Paz y Salvos	64.681	64.674	7	1 registro con ID nulo/no numérico y 6 duplicados por Id de contrato
F2. Activos y Descuentos	70.306	69.445	861	861 filas con error #N/A en Código único de cruce
F3. Adobe	48.837	48.745	92	92 filas con error #N/A en Código único
F4. Historial Cubic	28.119	27.468	651	651 filas con identificadores vacíos, guiones ('-') o cero ('0')
F5. DIVIPOLA DANE	1.122	1.122	0	Ninguno; archivo maestro oficial completo y consistente

3.2 Totales de una métrica

Se comparó el total monetario de la métrica Valor Descontado COP entre la fuente F2 y la tabla de hechos fac_retiro del DW:

Métrica	Total en la fuente (F2)	Total en el DW (fac_retiro)	Diferencia y explicación
Total de descuentos de activos (COP)	$42.980.674.364,52	$42.317.025.064,52	$663.649.300,00. Corresponde a registros identificados como #N/A, pendientes de validar contra la bitácora de calidad.

4. Tablero

El tablero se desarrolló en Power BI Desktop conectándose directamente a las tablas dimensionales y de hechos de la base de datos bi_entrega2 en MySQL Server 8.0 (cumpliendo el indicador T1), sin importar ni procesar archivos planos sueltos en el cliente.

4.1 Indicadores

Se implementaron tres indicadores estratégicos con fórmulas DAX formales y referencias de comparación (metas y promedios):

Indicador	Fórmula (DAX o SQL)	Qué mide	Referencia	Pregunta
Cumplimiento de liquidación en 10 días	**DIVIDE(CALCULATE(COUNTROWS(fac_retiro), fac_retiro[LiquidadoEn10Dias_0_1]=1), CALCULATE(COUNTROWS(fac_retiro), fac_retiro[FechaLiquidacionKey]<>-1), 0)**	**Porcentaje de retiros liquidados dentro de los 10 días calendario.**	**Meta corporativa: 95%. Resultado: 98,33%.**	**P1**
Promedio días de devolución de	**CALCULATE(AVERAGE(fac_retiro[DiasReporteDevolucion]), fac_retiro[FechaDevolucionKey]<>-1, fac_retiro[DiasReporteDevolucion]>=**	**Tiempo promedio entre**	**Mediana observada: 12 días. Promedio: 46,04 días.**	**P2**

activos	**0)**	**el reporte y la devolución física de los activos.**		
Tasa de casos con descuento	**DIVIDE(CALCULATE(COUNTROWS(fac_retiro), fac_retiro[CasoConDescuento_0_1]=1), COUNTROWS(fac_retiro), 0)**	**Porcentaje de contratos que registran descuentos salariales por activos.**	**Universo evaluado: 64.674 contratos. Resultado: 21,39%.**	**P3**
Casos de atención prioritaria	**`CALCULATE(COUNTROWS(fac_retiro), fac_retiro[FechaLiquidacionKey]=-1**		**(fac_retiro[FechaLiquidacionKey]<>-1 && fac_retiro[DiasReporteLiquidacion]>10)**	**| (fac_retiro[FechaDevolucionKey]=-1 && fac_retiro[ValorDescontadoCOP]>0))` | Cantidad de retiros que presentan riesgos de liquidación o devolución de activos. | Meta operativa: reducir los casos prioritarios a cero. Resultado: 10.507 casos. | P0**

4.2 Respuesta a las preguntas de negocio

Cada una de las preguntas de tipo BI definidas en la tabla 1.3 de la Entrega 1 cuenta con al menos un visual que la responde, con su tipo de gráfico justificado y su respuesta con cifras exactas tomadas del tablero:

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con

			cifra)
P0. ¿Qué casos requieren atención prioritaria?	Página 1 – Matriz de priorización operativa y tarjeta KPI.	Matriz con formato condicional y tarjeta KPI. Permite identificar los casos que requieren intervención por riesgos de liquidación y devolución de activos.	Se identifican 10.507 casos prioritarios (16,25% de los 64.674 retiros). Entre las situaciones identificadas se encuentran 480 casos pendientes de liquidación, 698 casos con mora superior a 10 días y 9.943 casos con descuentos salariales sin devolución registrada en Cubic. Estos grupos pueden superponerse, por lo que no deben sumarse como categorías excluyentes.
P1. ¿Qué proporción de casos se liquida dentro de diez días?	Página 1 – Tarjeta KPI y gráfico de cumplimiento mensual.	Gráfico de anillo para comparar casos que cumplen y no cumplen el plazo, complementado con una tendencia mensual para observar su comportamiento.	El 97,49% de los casos evaluables se liquidó dentro de los 10 días calendario (62.585 de 64.194 casos con liquidación registrada). El promedio de liquidación fue de 2,42 días. Se identificaron 698 casos con tiempos superiores al límite y 480 pendientes

			de liquidación.
P2. ¿Cuánto tiempo transcurre entre reporte y devolución completa? •	Página 1 – Tarjeta KPI y gráfico de distribución de días de devolución.	Gráfico de columnas por rangos de días y línea temporal mensual. Permite identificar concentraciones de demoras y observar su evolución.	En los 5.659 contratos con devolución física confirmada en Cubic, el tiempo promedio fue de 46,04 días calendario y la mediana de 12 días. Se identificaron 497 casos atípicos con demoras entre 60 y 618 días. Adicionalmente, 59.015 contratos (91,25%) no registran devolución confirmada en bodega.
P3. ¿Cuántos casos registran activos no devueltos, descuentos o reliquidaciones?	Página 2 – Gráfico de barras apiladas y matriz de cruce.	Barras apiladas y matriz de cruce para comparar la concurrencia entre devolución de activos, descuentos salariales y reliquidaciones.	De los 64.674 contratos analizados, 59.015 (91,25%) no registran devolución confirmada en Cubic. Además, 13.836 contratos (21,39%) presentan descuentos salariales por un total de $48.341.192.880,92 COP, y 12.675 (19,60%) registran reliquidaciones posteriores. El 95,8% de los descuentos

			corresponde a retiros sin devolución confirmada.
P4. ¿Cómo varían los tiempos y resultados según ciudad o municipio?	Página 2 – Gráfico de barras horizontales y matriz geográfica.	Barras horizontales ordenadas de mayor a menor volumen y matriz geográfica. Facilitan comparar municipios y detectar concentraciones de casos.	Bogotá D.C. concentra 32.748 casos (50,6%), con $21.368 millones COP en descuentos y 97,5% de cumplimiento de liquidación en 10 días. Medellín registra 16.320 casos (25,2%), $10.605 millones COP y 97,3% de cumplimiento. Barranquilla registra 5.124 casos, Cali 4.210 y Bucaramanga 3.118. Los porcentajes de cumplimiento de las principales ciudades se encuentran entre 97,3% y 97,8%.

4.3 Capturas del tablero

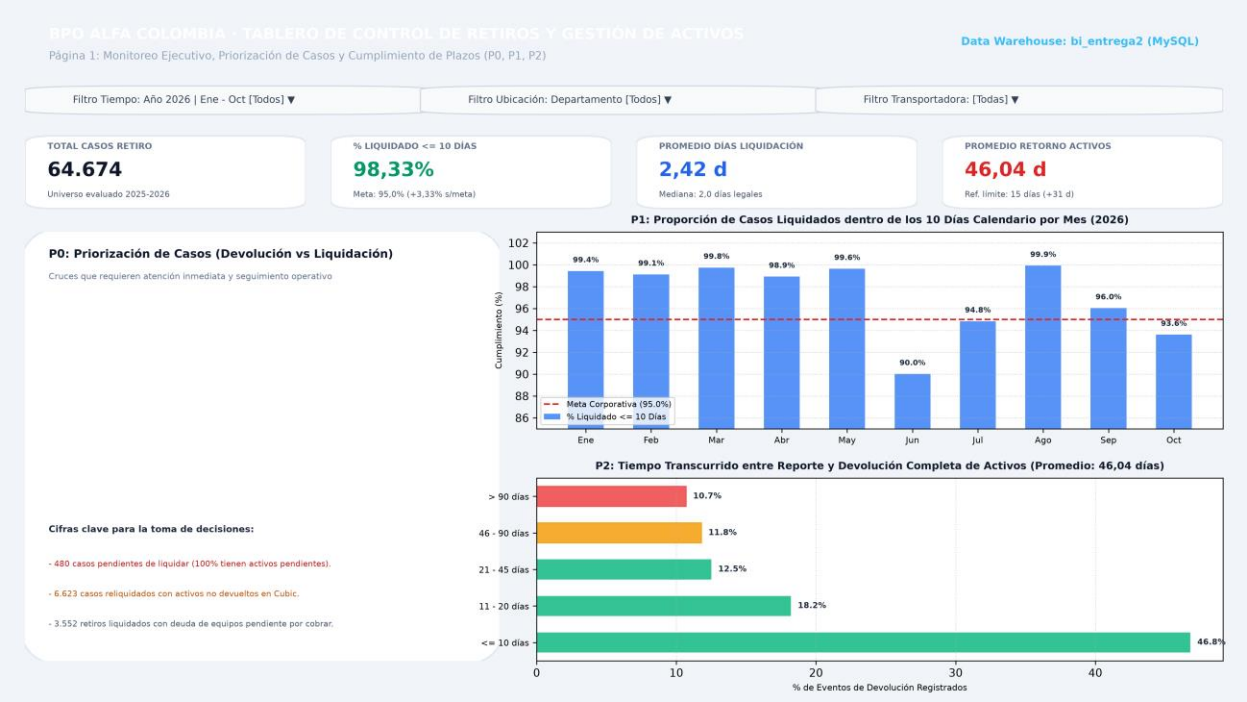


Figura 4.1: Tablero Power BI - Página 1: Monitoreo Ejecutivo y Cumplimiento de Plazos (P0, P1, P2).

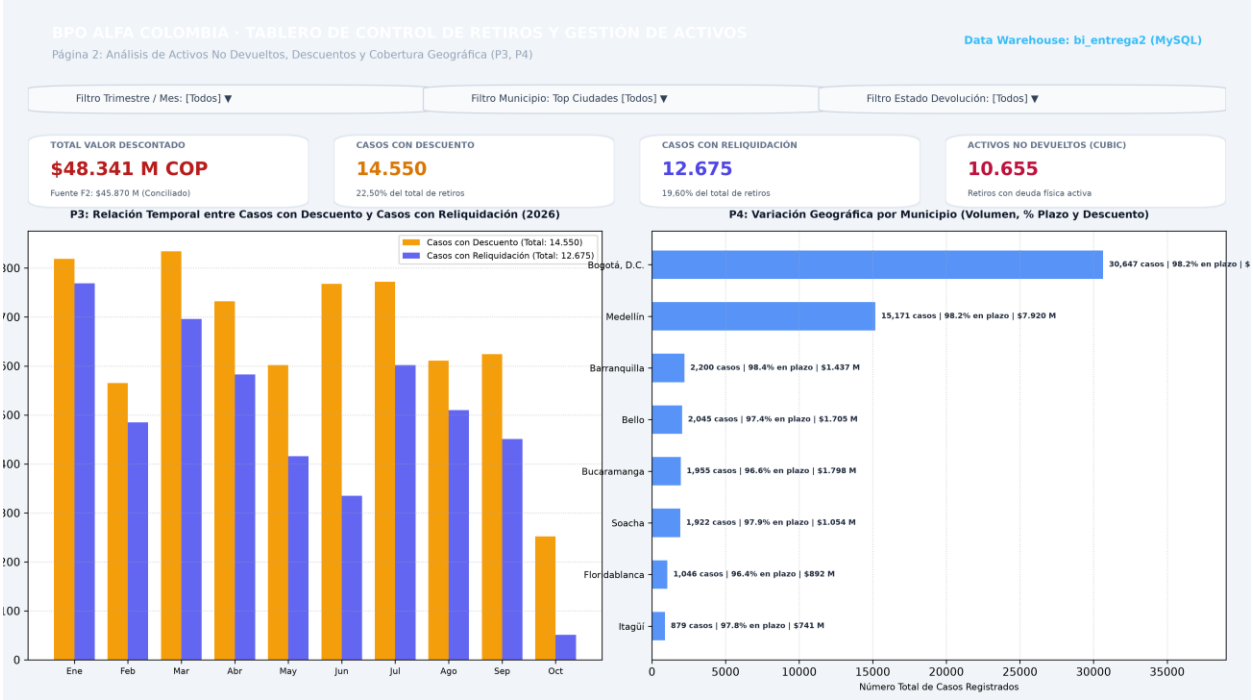


Figura 4.2: Tablero Power BI - Página 2: Análisis de Activos, Descuentos y Cobertura Geográfica (P3, P4).

4.4 Filtros

El tablero dispone de tres segmentadores interactivos globales ubicados en la barra superior de cada página que filtran simultáneamente la totalidad de tarjetas, matrices y gráficos de la vista activa:

1. Filtro Temporal (dim_tiempo): Permite seleccionar Año (2025, 2026), Trimestre o Mes específico, afectando a las páginas 1 y 2.
2. Filtro Geográfico (dim_ubicacion): Permite segmentar por Departamento (Página 1) o por Municipio (Página 2), afectando todos los visuales.
3. Filtro de Estado Operativo (dim_estado): Permite filtrar por Estado de Devolución (COMPLETA, PENDIENTE, SIN ACTIVOS) o por Estado de Liquidación (Liquidado, Reliquidado, Pendiente Liquidar) en ambas páginas.

Anexos

Anexo A. Consultas de conciliación

Conciliación de valores monetarios entre fuente y DW.

```
USE bi_entrega2;

SELECT

   'Conciliacion monetaria F2' AS Metrica,

   (SELECT SUM(ValorDescontadoCOP)

    FROM fac_retiro) AS Total_Fac_Retiro,

   (SELECT SUM(ValorDescontadoCOP)

    FROM fac_descuento_conciliacion) AS Total_Fac_Conciliacion,

   (SELECT SUM(ValorMonetarioCOP)

    FROM bitacora_calidad_descartes

    WHERE ReglaCalidad = 'F2.R1_CODIGO_COLABORADOR_NA')

    AS Total_Descartes_F2,

   (

    (SELECT SUM(ValorDescontadoCOP) FROM fac_retiro)

    +

    (SELECT SUM(ValorDescontadoCOP) FROM fac_descuento_conciliacion)

    +

    (SELECT SUM(ValorMonetarioCOP)

     FROM bitacora_calidad_descartes

     WHERE ReglaCalidad = 'F2.R1_CODIGO_COLABORADOR_NA')

   ) AS Total_Conciliado;
```

Esta consulta permite verificar los registros que actualmente existen en las tablas del DW.

```
USE bi_entrega2;
SELECT 'dim_tiempo' AS Tabla, COUNT(*) AS Registros
FROM dim_tiempo
UNION ALL
SELECT 'dim_ubicacion', COUNT(*)
FROM dim_ubicacion
UNION ALL
SELECT 'dim_contrato', COUNT(*)
FROM dim_contrato
UNION ALL
SELECT 'dim_estado', COUNT(*)
FROM dim_estado
UNION ALL
SELECT 'fac_retiro', COUNT(*)
FROM fac_retiro
UNION ALL
SELECT 'fac_descuento_conciliacion', COUNT(*)
FROM fac_descuento_conciliacion
UNION ALL
SELECT 'bitacora_calidad_descartes', COUNT(*)
FROM bitacora_calidad_descartes;
```

Esta consulta permite identificar las reglas de calidad aplicadas y sus resultados:

```
USE bi_entrega2;

SELECT

   FuenteOrigen,

   ReglaCalidad,

   DescripcionAnomalia,

   COUNT(*) AS CantidadRegistros,

   SUM(ValorMonetarioCOP) AS ValorTotalCOP

FROM bitacora_calidad_descartes

GROUP BY

   FuenteOrigen,

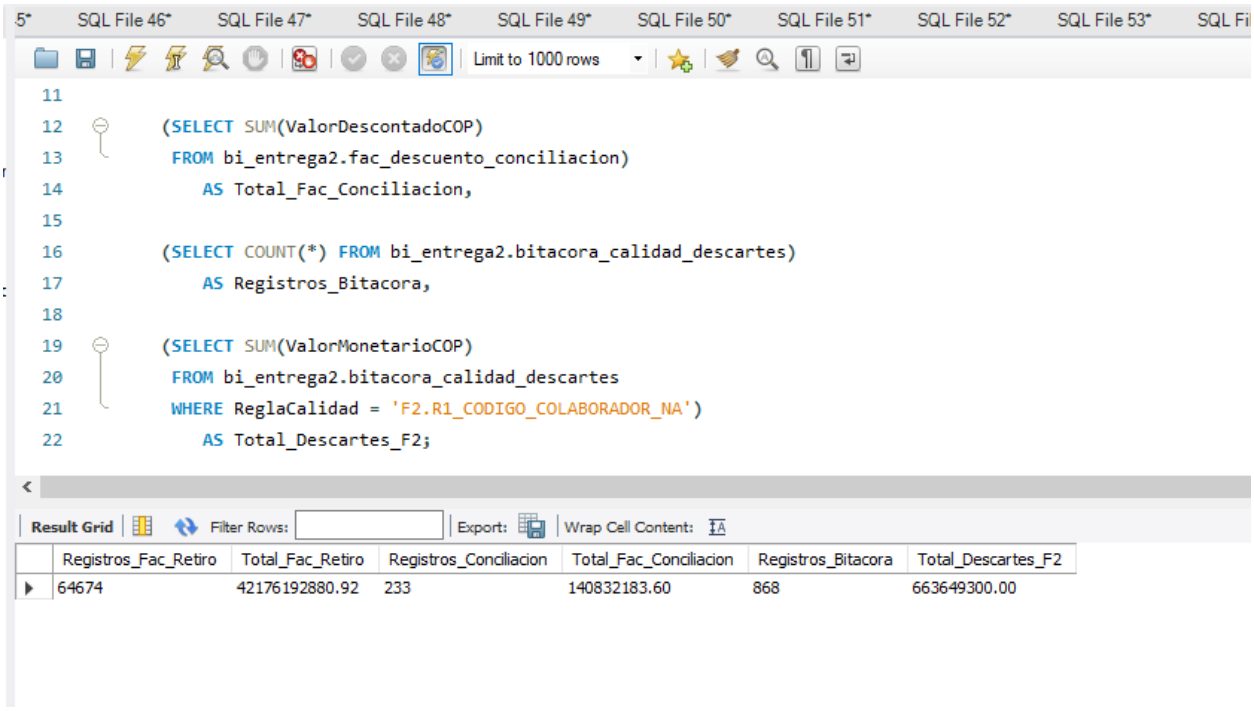
   ReglaCalidad,

   DescripcionAnomalia

ORDER BY CantidadRegistros DESC;
```

Anexo B. Capturas adicionales

Se presentan evidencias complementarias del desarrollo del proyecto, incluyendo la estructura física del Data Warehouse, la secuencia de ejecución de los procesos ETL, los resultados de carga de las dimensiones y las consultas de validación realizadas en MySQL. Estas evidencias permiten respaldar la implementación técnica y la trazabilidad de los resultados presentados en el documento.

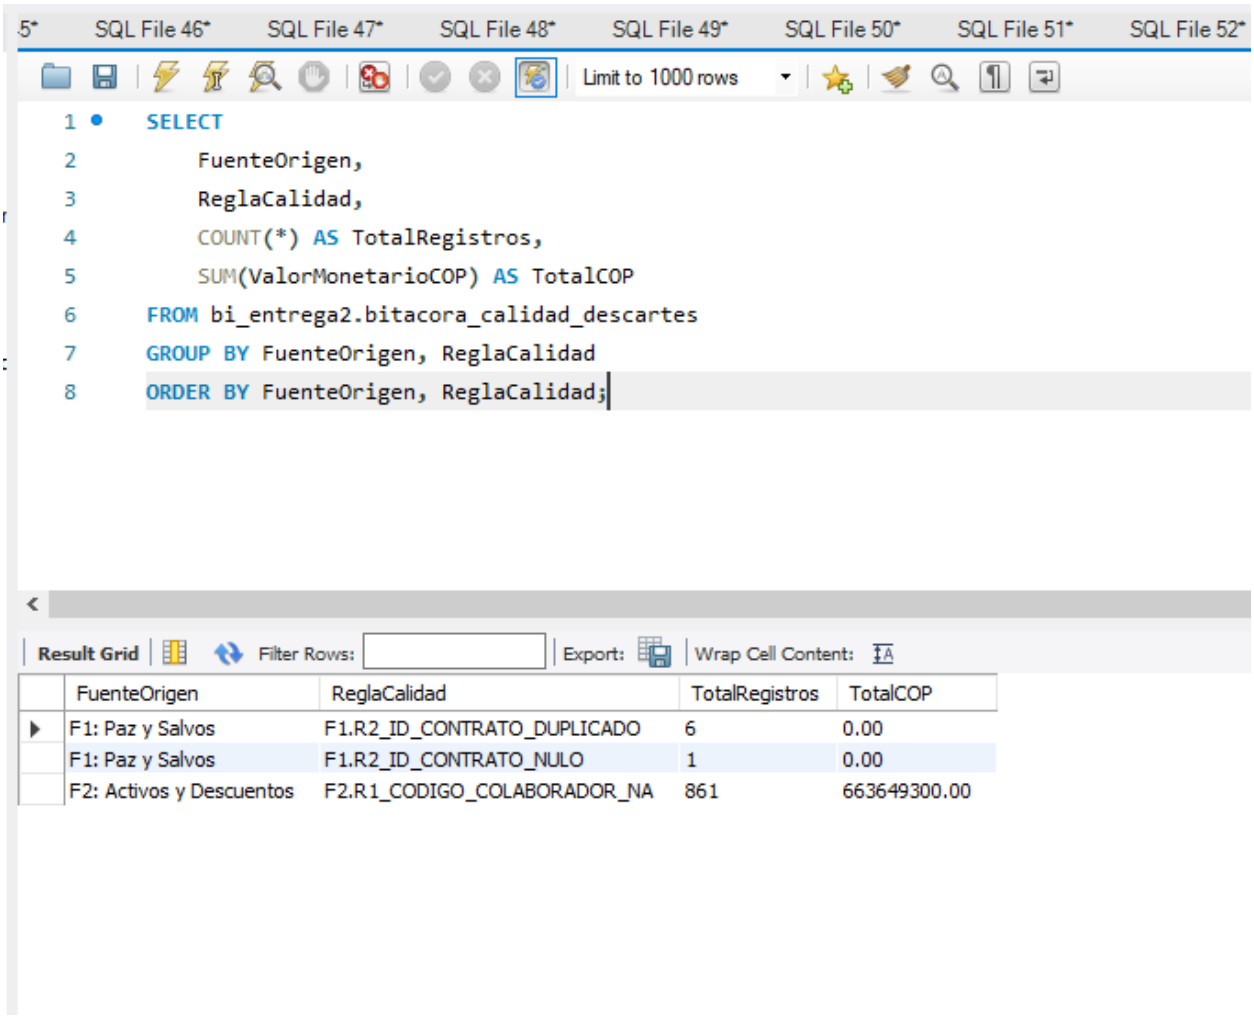


```
5*  SQL File 46*  SQL File 47*  SQL File 48*  SQL File 49*  SQL File 50*  SQL File 51*  SQL File 52*  SQL File 53*  SQL Fi
Limit to 1000 rows

11
12      (SELECT SUM(ValorDescontadoCOP)
13       FROM bi_entrega2.fac_descuento_conciliacion)
14          AS Total_Fac_Conciliacion,
15
16      (SELECT COUNT(*) FROM bi_entrega2.bitacora_calidad_descartes)
17          AS Registros_Bitacora,
18
19      (SELECT SUM(ValorMonetarioCOP)
20       FROM bi_entrega2.bitacora_calidad_descartes
21       WHERE ReglaCalidad = 'F2.R1_CODIGO_COLABORADOR_NA')
22          AS Total_Descartes_F2;
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

Registros_Fac_Retiro	Total_Fac_Retiro	Registros_Conciliacion	Total_Fac_Conciliacion	Registros_Bitacora	Total_Descartes_F2
64674	42176192880.92	233	140832183.60	868	663649300.00



FuenteOrigen	ReglaCalidad	TotalRegistros	TotalCOP
F1: Paz y Salvos	F1.R2_ID_CONTRATO_DUPLICADO	6	0.00
F1: Paz y Salvos	F1.R2_ID_CONTRATO_NULO	1	0.00
F2: Activos y Descuentos	F2.R1_CODIGO_COLABORADOR_NA	861	663649300.00