Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

BPO Alfa Colombia

Integrante	Código
Angie Natali Sánchez Muñoz	507232753
Juana Valentina Sotomayor Niño	507232708

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	13/11/2026
Repositorio	https://github.com/Angiensanchezm-jpg/bi-proyecto-equipo-AngieSanchez-507232753-JuanaSotomayor-507232708
Entorno del modelo	Python 3.13 en Jupyter Notebook (pandas 3.0.6, scikit-learn 1.9.1, SQLAlchemy 2.1.3)

Resumen de la entrega

En esta tercera entrega se desarrolla y despliega un modelo predictivo de Business Analytics (BA) sobre el Data Warehouse bi_entrega2 construido en la Entrega 2 para BPO Alfa Colombia. El modelo responde la pregunta de negocio de tipo BA (P5): ¿Qué casos de retiro reportados requerirán un reproceso de reliquidación (CasoConReliquidacion_0_1 = 1) según las características operativas del contrato, la transportadora asignada, la ubicación geográfica, la congestión logística del mes anterior y los descuentos por activos asociados? A partir de los 64.674 registros históricos extraídos mediante SQL (octubre de 2024 a octubre de 2026), se realizó una partición estrictamente temporal entrenando con los retiros de octubre de 2024 a mayo de 2026 (51.846 casos) y evaluando sobre el periodo más reciente de junio a octubre de 2026 (12.828 casos). Se entrenaron y compararon dos algoritmos de clasificación supervisada: Regresión Logística y Bosque Aleatorio (Random Forest Classifier). Se eligió el Bosque Aleatorio por presentar el mejor desempeño sobre el conjunto de prueba, alcanzando una Sensibilidad (Recall) del 99,33 % (detectó preventivamente 1.936 de los 1.949 casos reales de reliquidación y solo dejó pasar 13 casos), una exactitud global del 92,52 %, un F1-Score del 80,13 % y un área bajo la curva ROC-AUC del 97,89 %, superando ampliamente el criterio de éxito establecido (>= 85,0 % de sensibilidad). En respuesta a la pregunta de negocio, para el periodo evaluado de junio a octubre de 2026 el modelo identifica 2.883 retiros en alerta de reliquidación, concentrados en un 89,1 % en las transportadoras BSL (1.718 alertas frente a 1.158 casos reales) y LC (852 alertas frente a 556 casos reales), permitiendo al analista senior de Paz y Salvos activar la gestión preventiva de recolección desde el día 1 del reporte antes del cierre de nómina.

1. Comprensión del negocio

1.1 Pregunta y decisión

En la Tabla 1.3 de la Entrega 1 se formularon cinco preguntas de negocio (P0 a P4) de tipo Business Intelligence (BI) orientadas al diagnóstico descriptivo del cumplimiento del plazo de diez días, los tiempos de devolución en Cúbic, los descuentos y la cobertura geográfica. Dado que la Tabla 1.3 original no incluía una pregunta predictiva de tipo Business Analytics (BA), se formula y justifica sobre el mismo caso de negocio de BPO Alfa Colombia la siguiente pregunta BA (identificada como P5), derivada directamente de la problemática operativa analizada en las preguntas P0 y P3:

Pregunta BA (P5): ¿Qué casos de retiro reportados tendrán que pasar por un reproceso de reliquidación (CasoConReliquidacion_0_1 = 1) según las condiciones operativas del contrato (transportadora asignada, compañía, motivo de retiro), la ubicación geográfica, el comportamiento operativo del mes anterior y la aplicación de descuentos por activos?

Justificación sobre el caso: En BPO Alfa Colombia, cuando un excolaborador no devuelve a tiempo sus herramientas de trabajo (computador, diadema, token) o se aplica un descuento que posteriormente debe ajustarse por entrega extemporánea o conciliación de inventario, la empresa debe ejecutar una reliquidación del contrato (12.675 casos históricos, equivalentes al 19,60 % del total de retiros). Cada reliquidación implica costos ocultos de reproceso contable, ajustes de nómina, reclamos laborales y fricción entre el área de Paz y Salvos y las cuatro personas encargadas de gestionar las transportadoras. Por ello, contar con una predicción temprana de qué retiros tienen alta probabilidad de terminar en reliquidación cierra la brecha entre el monitoreo histórico (BI) y la acción preventiva (BA).

Decisión que apoyará el modelo: Con las predicciones del modelo desplegadas en el Data Warehouse y en el tablero de Power BI, el analista senior del proceso de Paz y Salvos y los cuatro líderes operativos de transportadora tomarán la decisión de priorizar preventivamente la recolección física y el contacto directo por WhatsApp desde el día 1 del reporte en los contratos clasificados con riesgo alto (probabilidad >= 60 %), exigiendo confirmación anticipada del estado del activo a las transportadoras críticas (BSL, LC y RABLAN) antes de ejecutar el cierre inicial de la liquidación.

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	CasoConReliquidacion_0_1 (Variable binaria: 1 = El retiro requiere reproceso de reliquidación; 0 = Cierre normal sin reliquidación).
Tipo de problema	Clasificación binaria supervisada (predice la categoría de resultado operativo y financiero de cada retiro).
Unidad de predicción	Una predicción por cada caso de retiro (identificado de forma única por CasoKey e IDContrato en fac_retiro).

1.3 Criterio de éxito

Dado que en el proceso de Paz y Salvos el error más costoso para BPO Alfa Colombia es no detectar a tiempo un caso que terminará en reproceso de reliquidación (Falso Negativo), pero también se requiere mantener

controlada la carga operativa de alertas (Exactitud global), el criterio de éxito medible se define sobre la matriz de confusión del conjunto de prueba (junio a octubre de 2026) en los siguientes términos:

Criterio de éxito medible: «De cada 100 casos de retiro que realmente requieren reliquidación en el conjunto de prueba, el modelo debe detectar preventivamente al menos 85 (Sensibilidad o Recall de la clase positiva >= 85,0 %, es decir, al menos 8,5 de cada 10 casos reales), manteniendo simultáneamente una Exactitud global (Accuracy) >= 90,0 % sobre el total de casos evaluados».

2. Comprensión de los datos

2.1 Consulta de extracción

El conjunto de datos se extrae directamente desde el Data Warehouse bi_entrega2 en MySQL utilizando la consulta almacenada en el archivo modelo/extraccion.sql del repositorio. La consulta realiza un INNER JOIN desde la tabla central de hechos fac_retiro hacia las cuatro tablas de dimensiones del esquema estrella: dim_tiempo (a través de FechaReporteKey = FechaKey), dim_ubicacion (UbicacionKey), dim_contrato (ContratoKey) y dim_estado (EstadoKey). No se excluyen registros mediante cláusulas WHERE restrictivas para preservar la totalidad del universo auditable del almacén de datos (64.674 casos de retiro), ordenando el resultado cronológicamente por la fecha de reporte (t.Fecha ASC, f.CasoKey ASC) para garantizar la integridad de la partición temporal.

```
-- ============================================================================
-- PROYECTO FINAL BI & DATA ANALYTICS - ENTREGA 3: MODELO PREDICTIVO
-- Caso: BPO Alfa Colombia
-- Equipo: Angie Natali Sánchez Muñoz (507232753)
--         Juana Valentina Sotomayor Niño (507232708)
-- Descripción: Consulta SQL de extracción del conjunto de datos desde el
--              Data Warehouse (bi_entrega2) uniendo la tabla de hechos
--              fac_retiro con sus cuatro dimensiones (dim_tiempo,
--              dim_ubicacion, dim_contrato, dim_estado).
-- ============================================================================

SELECT
    -- 1. Llaves del modelo dimensional (para trazabilidad y despliegue en pred_*)
    f.CasoKey,
    f.ContratoKey,
    f.UbicacionKey,
    f.EstadoKey,
    f.FechaReporteKey,

    -- 2. Atributos temporales del reporte (dim_tiempo)
    t.Fecha                   AS FechaReporte,
    t.Anio                    AS AnioReporte,
    t.Trimestre               AS TrimestreReporte,
    t.Mes                     AS MesReporte,
    t.NombreMes               AS NombreMesReporte,
    t.SemanaAnio              AS SemanaReporte,
    t.EsFinDeSemana           AS ReporteFinDeSemana,

    -- 3. Atributos geográficos de la sede / colaborador (dim_ubicacion)
    u.CodigoDepartamento,
    u.NombreDepartamento,
    u.CodigoMunicipio,
    u.NombreMunicipio,
    u.TipoEntidad,
```

```
    -- 4. Atributos contractuales y operativos (dim_contrato)
    c.IDContrato,
    c.CodigoUnicoAnonimizado,
    c.MotivoRetiro,
    c.Cargo,
    c.Compania,
    c.Transportadora,
    c.CECO,

    -- 5. Atributos de estado operativo y métricas en la tabla de hechos
    e.EstadoDevolucion,
    e.EstadoLiquidacion,
    f.DiasReporteLiquidacion,
    f.LiquidadoEn10Dias_0_1,
    f.CantidadActivosPendientes,
    f.CasoConDescuento_0_1,
    f.ValorDescontadoCOP,

    -- 6. Variable Objetivo (Target) para el modelo de Clasificación (Pregunta BA)
    f.CasoConReliquidacion_0_1
FROM fac_retiro f
INNER JOIN dim_tiempo    t ON f.FechaReporteKey = t.FechaKey
INNER JOIN dim_ubicacion u ON f.UbicacionKey    = u.UbicacionKey
INNER JOIN dim_contrato  c ON f.ContratoKey     = c.ContratoKey
INNER JOIN dim_estado    e ON f.EstadoKey       = e.EstadoKey
ORDER BY t.Fecha ASC, f.CasoKey ASC;
```

2.2 Descripción del conjunto de datos

El conjunto de datos extraído del Data Warehouse contiene exactamente 64.674 registros (una fila por cada caso de retiro asociado a un contrato) y cubre el periodo comprendido entre el 14 de octubre de 2024 y el 15 de octubre de 2026. A continuación, la Tabla 2.2 detalla cada variable extraída, su tipo de dato, su papel dentro del modelo analítico (objetivo, entrada o llave de identificación/despliegue) y su tabla y columna de origen en el Data Warehouse:

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
CasoConReliquidacion_0_1	Numérica (Binaria 0/1)	Objetivo	fac_retiro.CasoConReliquidacion_0_1	Indicador de si el caso tuvo reliquidación registrada (1 = Sí, 0 = No).
CasoKey	Numérica (Entera)	Identificador / Llave	fac_retiro.CasoKey	Llave primaria subrogada del caso de retiro en la tabla de hechos.
ContratoKey	Numérica (Entera)	Identificador / Llave	fac_retiro.ContratoKey	Llave foránea hacia la dimensión de contratos (dim_contrato).
UbicacionKey	Numérica (Entera)	Identificador / Llave	fac_retiro.UbicacionKey	Llave foránea hacia la dimensión geográfica

				DIVIPOLA (dim_ubicacion).
EstadoKey	Numérica (Entera)	Identificador / Llave	fac_retiro.EstadoKey	Llave foránea hacia la dimensión de estado operativo (dim_estado).
FechaReporteKey	Numérica (Entera)	Identificador / Llave	fac_retiro.FechaReporteKey	Llave foránea hacia dim_tiempo en formato AAAAMMDD.
FechaReporte	Fecha (Date)	Control temporal	dim_tiempo.Fecha	Fecha calendario en que se reportó el retiro (criterio de corte temporal).
AnioReporte	Numérica (Entera)	Control temporal	dim_tiempo.Anio	Año del reporte del retiro (2024, 2025 o 2026).
TrimestreReporte	Numérica (Entera)	Entrada	dim_tiempo.Trimestre	Trimestre calendario del reporte (1 a 4).
MesReporte	Numérica (Entera)	Entrada	dim_tiempo.Mes	Mes calendario del reporte del retiro (1 a 12).
ReporteFinDeSemana	Numérica (Binaria 0/1)	Entrada	dim_tiempo.EsFinDeSemana	Indica si el reporte ocurrió en sábado o domingo (1 = Sí, 0 = No).
NombreDepartamento	Categórica (Texto)	Entrada	dim_ubicacion.NombreDepartamento	Departamento oficial DANE donde se ubica el caso (33 departamentos).
CodigoMunicipio	Categórica (Texto)	Entrada (para rezago)	dim_ubicacion.CodigoMunicipio	Código DIVIPOLA del municipio de operación del excolaborador.
MotivoRetiro	Categórica (Texto)	Entrada	dim_contrato.MotivoRetiro	Causa de retiro: Voluntario, Involuntario, Mutuo Acuerdo, Prácticas.

Compania	Categórica (Texto)	Entrada	dim_contrato.Compania	Campaña o cliente corporativo para el cual operaba el colaborador.
Transportadora	Categórica (Texto)	Entrada	dim_contrato.Transportadora	Operador logístico asignado para la recolección de activos (BSL, LC, etc.).
EstadoDevolucion	Categórica (Texto)	Entrada	dim_estado.EstadoDevolucion	Estado físico de activos: SIN ACTIVOS, PENDIENTE o COMPLETA.
DiasReporteLiquidacion	Numérica (Entera)	Entrada	fac_retiro.DiasReporteLiquidacion	Días calendario transcurridos entre el reporte del retiro y su liquidación.
LiquidadoEn10Dias_0_1	Numérica (Binaria 0/1)	Entrada	fac_retiro.LiquidadoEn10Dias_0_1	Cumplimiento del plazo objetivo de liquidación <= 10 días (1 = Sí, 0 = No).
CantidadActivosPendientes	Numérica (Entera)	Entrada	fac_retiro.CantidadActivosPendientes	Número de equipos pendientes de devolución en Cúbic para el caso.
CasoConDescuento_0_1	Numérica (Binaria 0/1)	Entrada	fac_retiro.CasoConDescuento_0_1	Indica si el retiro registra descuento económico por activos (1 = Sí, 0 = No).
ValorDescontadoCOP	Numérica (Decimal)	Entrada	fac_retiro.ValorDescontadoCOP	Monto total descontado en pesos colombianos (COP) asociado al contrato.

2.3 Distribución de la variable objetivo

Por tratarse de un problema de clasificación binaria, se analiza la proporción de cada clase de la variable objetivo CasoConReliquidacion_0_1 sobre el universo de 64.674 registros del Data Warehouse. Como se observa en la Figura 1, la clase 0 (Cierre normal sin reliquidación) agrupa 51.999 casos, que representan el

80,40 % del total, mientras que la clase 1 (Caso con reliquidación) comprende 12.675 casos, equivalentes al 19,60 % del total.

Interpretación de la distribución: Esta distribución muestra un desbalance moderado de aproximadamente 4 a 1 entre los retiros que cierran en un único ciclo y aquellos que sufren reproceso de reliquidación. Desde la perspectiva del negocio, una proporción del 19,60 % (casi 1 de cada 5 retiros) confirma la magnitud crítica del problema en BPO Alfa Colombia; desde la perspectiva técnica del modelado, este desbalance exige evaluar los algoritmos mediante la matriz de confusión, la sensibilidad (Recall) de la clase positiva y el F1-Score —en lugar de confiar únicamente en la exactitud global—, así como emplear ponderación balanceada en el entrenamiento del Bosque Aleatorio.

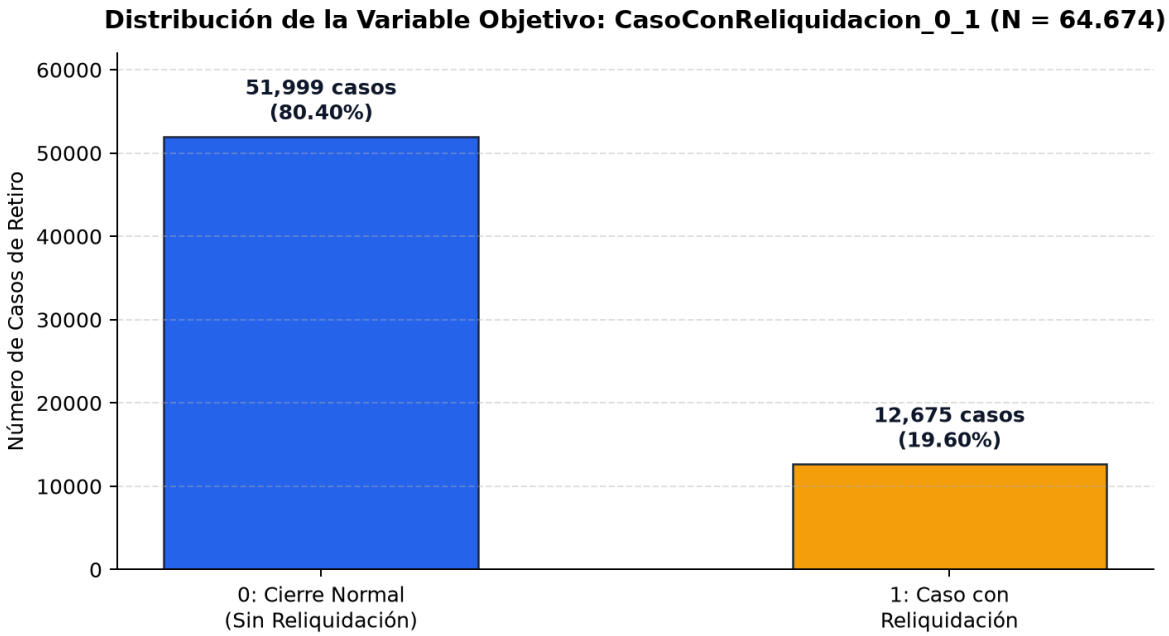


Figura 1. Distribución de clases de la variable objetivo CasoConReliquidacion_0_1 en bi_entrega2 (N = 64.674).

2.4 Análisis exploratorio

Con el fin de comprender qué factores operativos y contextuales explican la ocurrencia de reliquidaciones antes de entrenar los algoritmos, se construyeron cuatro gráficos exploratorios que cruzan las variables de entrada con la variable objetivo CasoConReliquidacion_0_1:

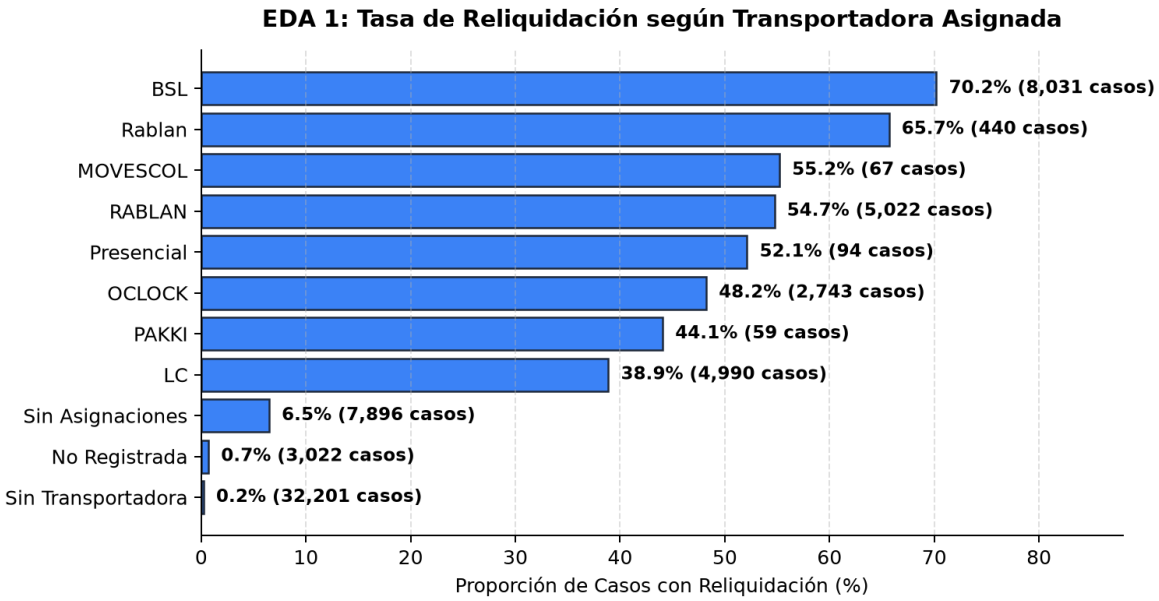


Figura 2 (Gráfico exploratorio 1). Proporción de casos con reliquidación según la transportadora asignada.

Interpretación del Gráfico Exploratorio 1 (Transportadora vs. Reliquidación): La transportadora asignada presenta una relación altamente discriminante con la variable objetivo: mientras que los retiros sin transportadora asignada (32.201 casos de personal sin activos por recoger) registran apenas un 0,2 % de reliquidación, los casos gestionados por operadores logísticos muestran tasas críticas encabezadas por BSL con 70,2 % (5.638 reliquidados de 8.031 casos), RABLAN con 55,6 % (3.038 de 5.462), Presencial con 52,1 %, OCLOCK con 48,2 % y LC con 38,9 %.

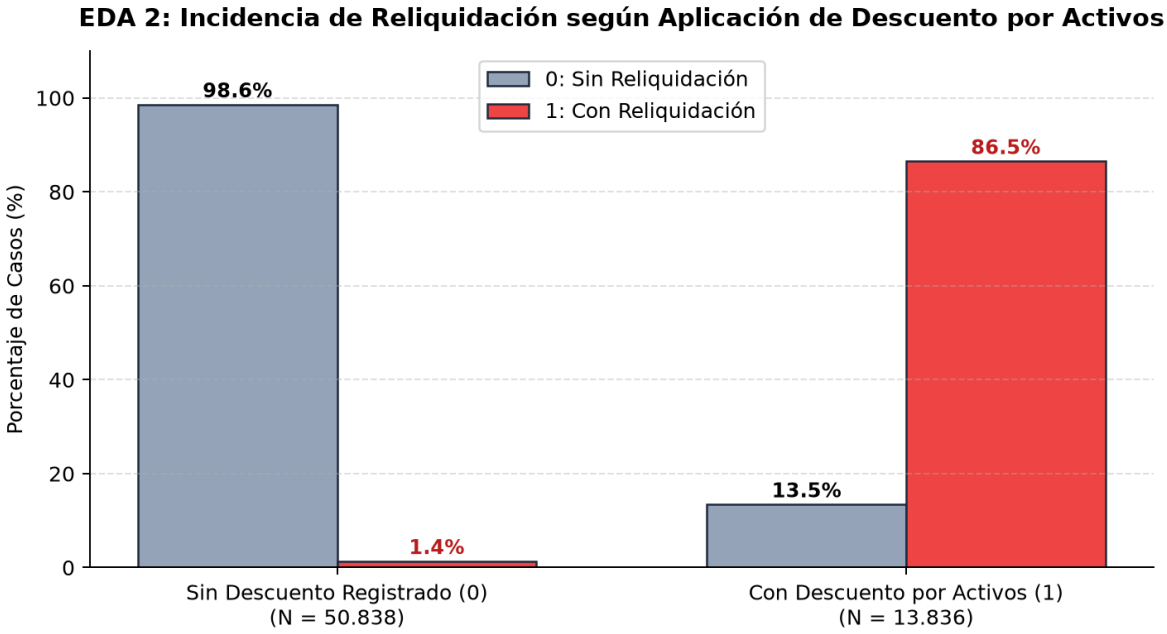


Figura 3 (Gráfico exploratorio 2). Incidencia de reliquidación según la aplicación de descuento por activos.

Interpretación del Gráfico Exploratorio 2 (Descuento por Activos vs. Reliquidación): Existe una asociación directa y contundente entre la aplicación de descuentos económicos por equipos no entregados

(CasoConDescuento_0_1) y el reproceso posterior de reliquidación: de los 13.836 contratos a los que se les aplicó descuento en la liquidación inicial, el 86,5 % (11.974 casos) terminó requiriendo una reliquidación posterior, mientras que entre los 50.838 casos sin descuento solo el 1,4 % (701 casos) presentó reliquidación.

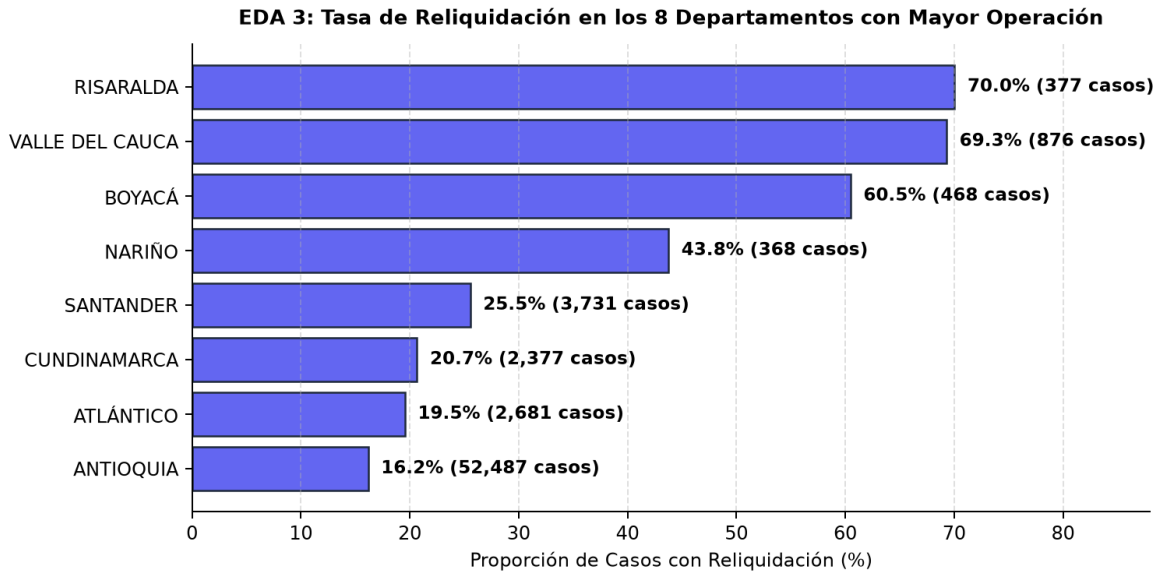


Figura 4 (Gráfico exploratorio 3). Tasa de reliquidación en los 8 departamentos con mayor volumen de retiros.

Interpretación del Gráfico Exploratorio 3 (Departamento vs. Reliquidación): El análisis geográfico evidencia que, aunque Antioquia concentra el mayor volumen absoluto de retiros (52.487 casos) con una tasa de reliquidación moderada del 16,2 %, las operaciones regionales fuera de la sede principal presentan vulnerabilidades logísticas mucho más severas: Risaralda alcanza un 70,0 % de reliquidación (264 de 377 casos), Valle del Cauca un 69,3 % (607 de 876), Boyacá un 60,5 % y Nariño un 43,8 %, debido a los mayores tiempos de tránsito en la recolección nacional de equipos.

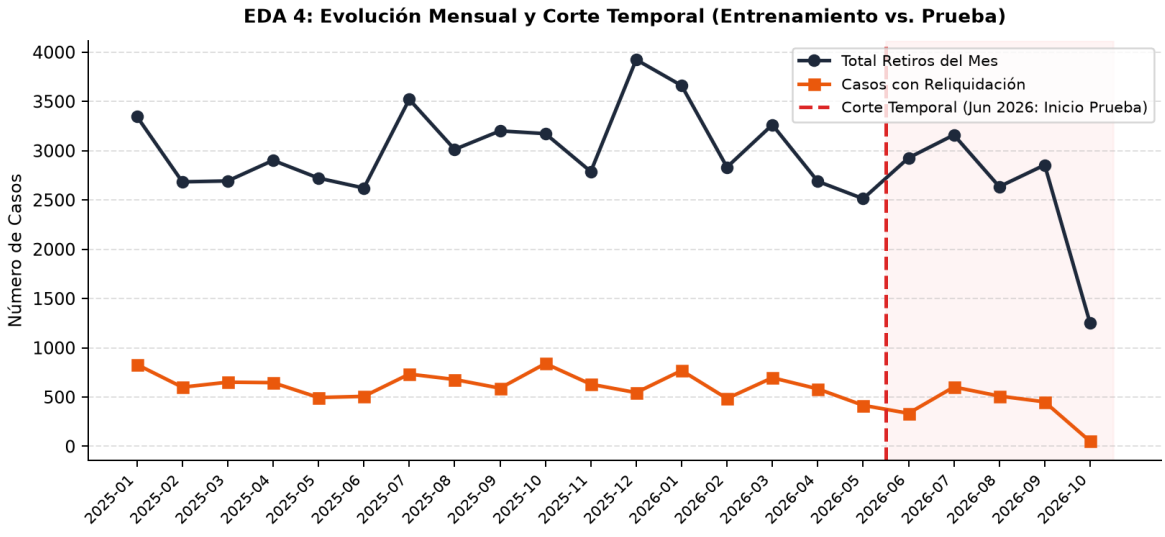


Figura 5 (Gráfico exploratorio 4). Evolución mensual de retiros y reliquidaciones (2025–2026) y corte temporal.

Interpretación del Gráfico Exploratorio 4 (Evolución Temporal y Partición): La serie mensual confirma un volumen operativo sostenido entre 2.500 y 3.900 retiros mensuales durante 2025 y 2026, con una incidencia

constante de reliquidaciones que justifica realizar el corte temporal en junio de 2026: los primeros 20 meses (octubre 2024 – mayo 2026) proveen una base histórica robusta de aprendizaje y los últimos 5 meses (junio – octubre 2026) permiten evaluar la capacidad de generalización hacia adelante.

3. Preparación de los datos

3.1 Limpieza y transformación

En la Tabla 3.1 se documenta de manera exhaustiva el tratamiento aplicado a los valores nulos, marcadores de ausencia, valores atípicos y variables categóricas antes del entrenamiento de los modelos, indicando el número exacto de registros afectados en cada regla:

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Nulos / Marcadores sin asignación	Transportadora	Los registros con guion '-' (32.201 casos sin activos físicos asignados) se estandarizaron en la categoría explícita 'Sin Transportadora', y los registros con texto 'NULL' o vacíos (3.022 casos) se imputaron como 'No Registrada'.	35.223 (32.201 con '-' y 3.022 con 'NULL')
Nulos en tiempo de liquidación	DiasReporteLiquidacion	Los casos que aún se encuentran en estado 'Pendiente Liquidar' y no poseen fecha de liquidación tienen valor NULL en DiasReporteLiquidacion; se imputaron con la mediana histórica del proceso (2,0 días) para conservar estos casos críticos.	480
Atípicos (Outliers)	DiasReporteLiquidacion	Se identificaron 911 registros con diferencias negativas (por desfase en fechas de captura en la fuente original) y 60 registros con demoras extremas mayores a 60 días; se aplicó acotamiento (winsorizing / clipping) al intervalo operativo [0, 60] días.	971 (911 menores a 0 d y 60 mayores a 60 d)
Asimetría monetaria extrema	ValorDescontadoCOP	Dado que el 78,6 % de los casos tiene descuento $0 y el 21,4 % restante alcanza hasta más de $10 millones COP, se aplicó la transformación logarítmica ln(1 + ValorDescontadoCOP) evitando que valores extremos distorsionen la Regresión Logística.	13.836 (casos con monto > 0)
Agrupación de alta cardinalidad	Compania y NombreDepartamento	Se conservaron las 12 compañías principales y los 8 departamentos de mayor volumen, agrupando las categorías minoritarias en 'Otras Compañías' y 'Otros Departamentos' para prevenir sobreajuste (overfitting).	29.115 (en compañías menores) y 1.724 (en deptos. menores)

Codificación categórica	Transportadora_Limpia, MotivoRetiro_Limpio, Compania_Agrupada, Depto_Agrupado, EstadoDevolucion	Se aplicó One-Hot Encoding (variables dummy 0/1 mediante pd.get_dummies) sobre las 5 variables categóricas limpias, generando 47 columnas binarias que junto a las 12 numéricas conforman las 59 variables de entrada. Adicionalmente, para la Regresión Logística se aplicó StandardScaler sobre las columnas numéricas ajustado únicamente con el conjunto de entrenamiento.	64.674 (100 % del conjunto de datos)

3.2 Variables derivadas

Se construyeron cuatro variables derivadas (ingeniería de características) a partir de las tablas del Data Warehouse. Para evitar cualquier fuga de información del futuro (data leakage), las variables históricas se calcularon utilizando exclusivamente el rezago del mes calendario anterior (t - 1), garantizando que todas se conocen antes del cierre o momento de la predicción:

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
TieneTransportadoraAsignada_0_1	Toma el valor 1 si Transportadora pertenece al grupo de operadores activos (BSL, RABLAN, LC, OCLOCK, Presencial, MOVESCOL, PAKKI) y 0 en caso contrario.	Separa de inmediato los retiros que requieren logística inversa física (donde ocurre más del 98 % de las reliquidaciones) de los retiros sin activos.	Sí (se asigna al reportar el retiro).
TasaReliqTranspMesAnterior	Proporción de casos que terminaron en reliquidación para esa misma transportadora durante el mes calendario inmediatamente anterior (t - 1).	Captura el nivel reciente de incumplimiento o rezago operativo del operador logístico asignado sin usar datos del mes actual.	Sí (se calcula al cierre del mes t - 1).
VolumenRetirosTranspMesAnterior	Conteo total de retiros gestionados por esa misma transportadora en el mes anterior (t - 1).	Mide la saturación o congestión de carga de trabajo reciente del operador logístico, que incrementa la demora en recolecciones.	Sí (se conoce al finalizar el mes t - 1).
TasaReliqMuniMesAnterior	Proporción de retiros reliquidados en el mismo municipio (CodigoMunicipio) durante el mes anterior (t - 1).	Refleja la dificultad logística estructural de la ciudad o sede del excolaborador en el periodo previo.	Sí (se conoce al finalizar el mes t - 1).

3.3 División en entrenamiento y prueba

Debido a que cada registro posee la fecha exacta de reporte del retiro (FechaReporte), se aplicó una división estrictamente temporal (Indicador P3): los modelos se entrenan con el pasado histórico (octubre de 2024 a mayo de 2026) y se evalúan sobre los últimos cinco meses disponibles en el Data Warehouse (junio a octubre de 2026), respetando una proporción cercana al 80 % / 20 %:

Conjunto	Registros	Periodo o proporción
Entrenamiento	51.846 registros (10.726 con reliquidación; 20,69 %)	14 de octubre de 2024 – 31 de mayo de 2026 (80,17 % del total de datos)
Prueba	12.828 registros (1.949 con reliquidación; 15,19 %)	1 de junio de 2026 – 15 de octubre de 2026 (19,83 % del total de datos)
Total general	64.674 registros (12.675 con reliquidación; 19,60 %)	Octubre de 2024 – Octubre de 2026 (100,00 % del Data Warehouse)

4. Modelado

4.1 Algoritmos

Se entrenaron dos algoritmos supervisados de clasificación binaria utilizando exactamente el mismo conjunto de entrenamiento (51.846 registros del periodo octubre 2024 – mayo 2026) y las mismas 59 variables de entrada:

Algoritmo	Por qué se eligió	Parámetros usados
Regresión Logística (LogisticRegression)	Es el modelo paramétrico lineal de referencia para clasificación binaria. Permite estimar probabilidades calibradas mediante la función logística y evaluar si una frontera de decisión lineal sobre las variables estandarizadas es suficiente para separar los casos que requerirán reliquidación.	C=0.05 (regularización L2 para evitar sobreajuste), penalty='l2', solver='lbfgs', max_iter=500, random_state=42 (con variables numéricas escaladas mediante StandardScaler).
Bosque Aleatorio (RandomForestClassifier)	Es un algoritmo de ensamble no lineal basado en múltiples árboles de decisión entrenados mediante bagging y selección aleatoria de atributos. Se eligió porque captura interacciones complejas no lineales (por ejemplo, combinaciones específicas entre transportadora, departamento, monto descontado y congestión del mes anterior) y es robusto frente a valores extremos.	n_estimators=200 (200 árboles), max_depth=12 (profundidad máxima controlada), min_samples_split=10, min_samples_leaf=4, class_weight='balanced_subsample' (ajuste por desbalance de clases en cada muestra bootstrap), random_state=42, n_jobs=-1.

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

Por tratarse de un problema de clasificación, ambos algoritmos se evaluaron sobre los 12.828 casos de retiro del conjunto de prueba temporal (junio a octubre de 2026), en el cual existen 1.949 retiros que realmente requirieron reliquidación (clase 1) y 10.879 retiros que tuvieron cierre normal sin reliquidación (clase 0). En la Figura 6 se presentan las matrices de confusión de ambos modelos y, a continuación, la Tabla de desempeño y la lectura detallada en términos del proceso operativo de BPO Alfa Colombia:

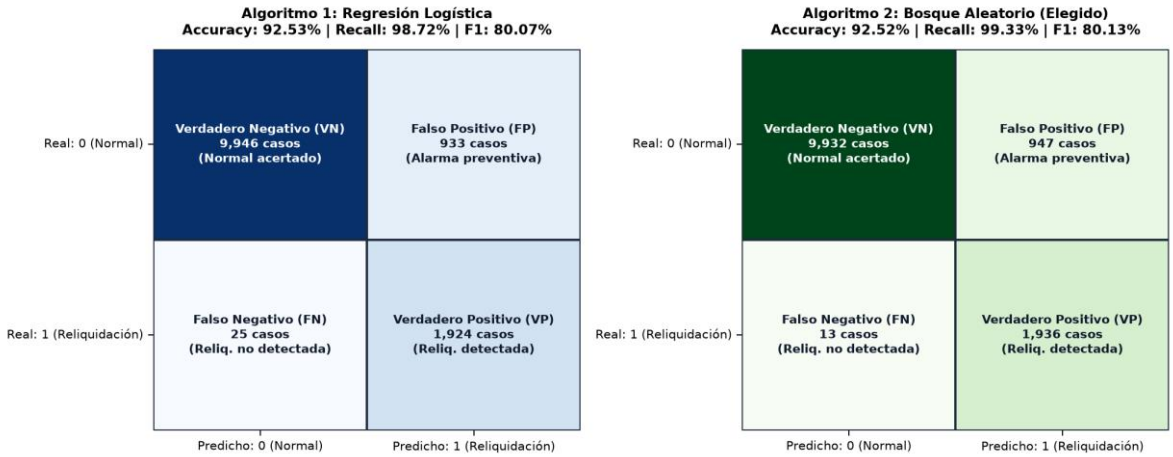


Figura 6. Matrices de confusión sobre el conjunto de prueba temporal (junio a octubre de 2026, N = 12.828).

Algoritmo	Verdaderos Negativos (VN)	Falsos Positivos (FP)	Falsos Negativos (FN)	Verdaderos Positivos (VP)	Exactitud (Accuracy)	Sensibilidad (Recall)	F1-Score / ROC-AUC
Regresión Logística	9.946	933	25	1.924	92,53 %	98,72 %	F1: 80,07 % | AUC: 96,92 %
Bosque Aleatorio (Random Forest)	9.932	947	13	1.936	92,52 %	99,33 %	F1: 80,13 % | AUC: 97,89 %

Lectura de la matriz de confusión — Algoritmo 1 (Regresión Logística): De los 1.949 casos de retiro entre junio y octubre de 2026 que realmente terminaron en reproceso de reliquidación, la Regresión Logística detectó correctamente 1.924 casos (Verdaderos Positivos, 98,72 %) y dejó pasar sin alerta a 25 casos que sí requirieron reliquidación (Falsos Negativos, 1,28 %). Por su parte, de los 10.879 retiros que tuvieron un cierre normal sin reliquidación, el modelo clasificó correctamente 9.946 casos (Verdaderos Negativos, 91,42 %) y marcó preventivamente como riesgo a 933 casos que finalmente no necesitaron reliquidación (Falsos Positivos, equivalentes a casos con descuento o activos gestionados donde el cobro inicial quedó en firme sin requerir ajuste posterior).

Lectura de la matriz de confusión — Algoritmo 2 (Bosque Aleatorio / Random Forest): De los mismos 1.949 casos reales de reliquidación ocurridos en el periodo de prueba, el Bosque Aleatorio detectó acertadamente 1.936 casos (Verdaderos Positivos, alcanzando una sensibilidad del 99,33 %) y únicamente dejó escapar 13 casos en los cinco meses evaluados (Falsos Negativos, apenas el 0,67 %, reduciendo casi a la mitad las omisiones frente a la Regresión Logística). Asimismo, sobre los 10.879 retiros de cierre normal, identificó correctamente 9.932 casos que no requerían intervención adicional (Verdaderos Negativos, 91,29 %) y

generó 947 alertas preventivas sobre contratos con riesgo operativo que lograron cerrarse sin reproceso (Falsos Positivos).

5.2 Comparación y elección

Se elige el Bosque Aleatorio (Random Forest Classifier) como el modelo definitivo para el despliegue en BPO Alfa Colombia, con base en tres argumentos cuantitativos derivados de las métricas del conjunto de prueba:

1. Menor número de reprocesos no detectados (Sensibilidad superior): En el mismo conjunto de prueba de 12.828 retiros, el Bosque Aleatorio alcanza una Sensibilidad (Recall) del 99,33 % frente al 98,72 % de la Regresión Logística (+0,61 puntos porcentuales). En términos operativos, el Bosque Aleatorio reduce los Falsos Negativos de 25 a solo 13 casos (12 casos reales adicionales de reliquidación detectados a tiempo), lo cual es decisivo porque cada Falso Negativo representa un retiro que pasa inadvertido y obliga a reabrir la liquidación contable.

2. Mayor F1-Score y capacidad discriminante global (ROC-AUC): El Bosque Aleatorio supera a la Regresión Logística tanto en el equilibrio armónico entre precisión y sensibilidad (F1-Score de 80,13 % vs. 80,07 %) como en el área bajo la curva ROC (ROC-AUC de 97,89 % vs. 96,92 %, una ventaja de +0,97 puntos porcentuales), lo que demuestra que ordena con mayor exactitud las probabilidades de riesgo para priorizar la cola de trabajo diario.

3. Captura de reglas no lineales por transportadora y región: Mientras la Regresión Logística asigna pesos fijos aditivos, el Bosque Aleatorio modela el efecto combinado entre el monto del descuento, la transportadora específica (BSL, LC, RABLAN) y la tasa de incumplimiento del mes anterior.

5.3 Variables más importantes

En la Figura 7 se presenta el gráfico con las 10 variables de mayor importancia relativa (impureza de Gini reducida) dentro del Bosque Aleatorio elegido:

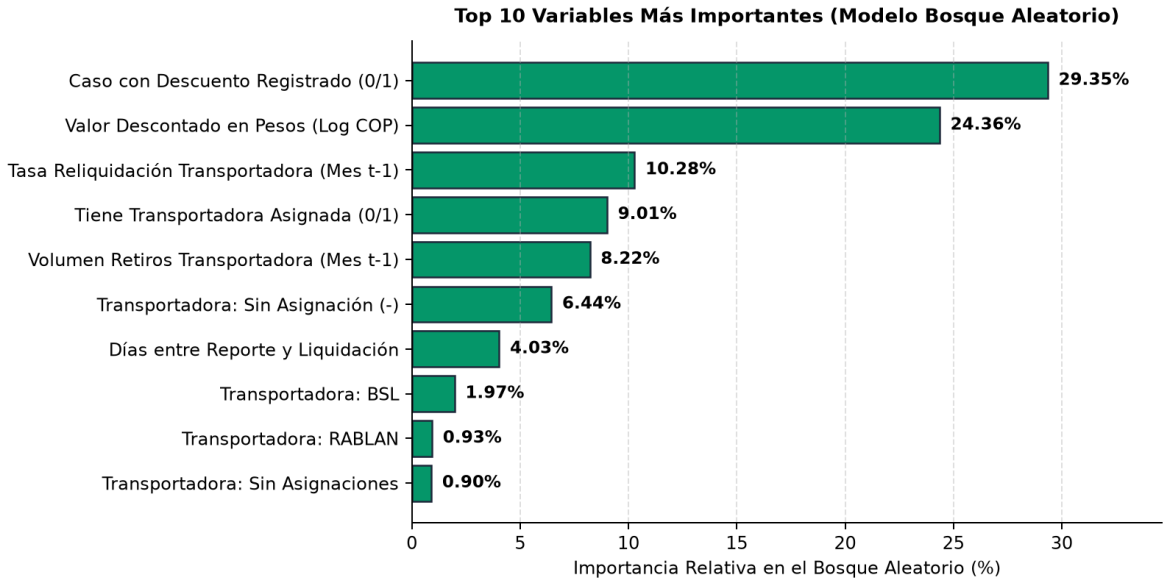


Figura 7. Importancia relativa de las 10 variables principales en el modelo elegido (Bosque Aleatorio).

Interpretación de las variables más importantes: Las cinco variables que concentran el 81,22 % del poder predictivo del Bosque Aleatorio tienen una traducción directa a la operación de BPO Alfa Colombia: (1)

CasoConDescuento_0_1 (29,35 %) y (2) LogValorDescontadoCOP (24,36 %) suman el 53,71 % de la importancia, confirmando que el registro de un descuento económico por equipos no devueltos a tiempo y su cuantía en pesos son el detonante principal de una reliquidación posterior cuando el excolaborador entrega el activo de forma extemporánea o solicita revisión del descuento; (3) TasaReliqTranspMesAnterior (10,28 %), (4) TieneTransportadoraAsignada_0_1 (9,01 %) y (5) VolumenRetirosTranspMesAnterior (8,22 %) aportan en conjunto el 27,51 %, demostrando que la asignación de una transportadora física y el rezago operativo que ese operador arrastraba en el mes inmediatamente anterior determinan la probabilidad de que el activo no llegue a tiempo a Cúbic antes del cierre de nómina. Finalmente, la ausencia de transportadora (6,44 %), los días entre reporte y liquidación (4,03 %) y los indicadores específicos de BSL (1,97 %) y RABLAN (0,93 %) completan el perfil de riesgo del caso.

5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
Detectar preventivamente al menos 85 de cada 100 casos que realmente requieren reliquidación en el conjunto de prueba (Sensibilidad / Recall >= 85,0 %) manteniendo una Exactitud global (Accuracy) >= 90,0 %.	Sensibilidad (Recall) = 99,33 % (1.936 detectados de 1.949 reales; más de 9,9 de cada 10 casos) y Exactitud global (Accuracy) = 92,52 % (F1 = 80,13 %, ROC-AUC = 97,89 %).	Sí

5.5 Respuesta a la pregunta de negocio

En respuesta a la pregunta BA formulada en la sección 1.1, para los 12.828 retiros del periodo reciente de evaluación (junio a octubre de 2026), el modelo de Bosque Aleatorio pronostica que 2.883 casos presentan riesgo activo de reproceso de reliquidación (logrando capturar 1.936 de los 1.949 casos que efectivamente terminaron reliquidados, el 99,33 %). Al desagregar las predicciones por operador logístico para orientar la gestión del área de Paz y Salvos, el modelo revela que el 89,1 % de los casos predichos en riesgo se concentra en dos únicas transportadoras: BSL, para la cual el modelo pronostica 1.718 casos en alerta (donde ocurrieron 1.158 reliquidaciones reales de 2.019 retiros), y LC, para la cual pronostica 852 casos en alerta (556 reliquidaciones reales de 1.951 retiros), seguidas por RABLAN con 252 casos pronosticados en riesgo (211 reales).

Decisión operativa y gerencial que apoya: Con estas cifras, el modelo apoya de forma directa dos decisiones concretas del analista senior de Paz y Salvos y su equipo de cuatro gestores: (1) Focalizar la capacidad de contacto preventivo por WhatsApp y seguimiento diario exclusivamente sobre los 2.883 contratos marcados por el modelo (el 22,5 % del flujo entrante) en lugar de revisar manualmente los 12.828 retiros, reduciendo en un 77,5 % la carga de verificación manual sin perder prácticamente ningún caso real (solo 13 omisiones en 5 meses); y (2) Establecer una mesa de conciliación anticipada con los operadores BSL y LC antes de aplicar el descuento en nómina sobre los contratos clasificados con NivelRiesgoPreventivo = 'ALTO' (probabilidad >= 0,60), verificando si el equipo ya fue recolectado en tránsito pero aún no ha sido cargado al Historial de Cúbic, evitando así ejecutar descuentos que obliguen a reliquidar el contrato semanas después.

6. Despliegue

6.1 Tabla de predicciones

Las predicciones generadas por el modelo elegido (RandomForestClassifier) se desplegaron directamente en el Data Warehouse MySQL bi_entrega2 dentro de la tabla pred_reliquidacion, cuyo script de creación DDL se encuentra en el repositorio en la ruta dw/ddl/08_pred_reliquidacion.sql. La tabla almacena los 64.674 registros del modelo dimensional (51.846 del corte de entrenamiento y 12.828 del corte de prueba) e incluye las llaves foráneas hacia dim_tiempo (FechaReporteKey), dim_ubicacion (UbicacionKey), dim_contrato (ContratoKey) y dim_estado (EstadoKey), permitiendo filtrar y cruzar las predicciones con cualquier dimensión en Power BI:

Columna	Tipo	Descripción
PrediccionKey	INT (PK, AUTO_INCREMENT)	Llave primaria subrogada única del registro de predicción en la tabla pred_reliquidacion.
CasoKey	INT (UNIQUE, NOT NULL)	Llave de negocio e identificador del caso de retiro (permite cruce 1:1 con fac_retiro).
ContratoKey	INT (FK, NOT NULL)	Llave foránea hacia dim_contrato (conecta con Transportadora, Compañía, Cargo y MotivoRetiro).
UbicacionKey	INT (FK, NOT NULL)	Llave foránea hacia dim_ubicacion (conecta con Departamento y Municipio DIVIPOLA).
EstadoKey	INT (FK, NOT NULL)	Llave foránea hacia dim_estado (conecta con EstadoDevolucion y EstadoLiquidacion).
FechaReporteKey	INT (FK, NOT NULL)	Llave foránea hacia dim_tiempo en formato AAAAMMDD (conecta con Año, Trimestre y Mes).
ConjuntoDatos	VARCHAR(20)	Identifica la partición temporal del registro: 'ENTRENAMIENTO' (51.846 filas) o 'PRUEBA' (12.828 filas).
RealReliquidacion_0_1	TINYINT(1)	Valor real observado de la variable objetivo en el DW (0 = Sin reliquidación, 1 = Reliquidado).
PrediccionReliquidacion_0_1	TINYINT(1)	Valor predicho por el Bosque Aleatorio elegido (0 = Cierre normal, 1 = Alerta de reliquidación).
ProbabilidadReliquidacion	DECIMAL(6,4)	Probabilidad continua estimada por el modelo (entre 0,0000 y 1,0000) para ordenar prioridades.
NivelRiesgoPreventivo	VARCHAR(20)	Semáforo operativo para el analista: 'ALTO' (prob >= 0,60), 'MEDIO' (0,30 a 0,59) o 'BAJO' (< 0,30).
ResultadoEvaluacion	VARCHAR(30)	Clasificación en la matriz de confusión: Verdadero Positivo (VP), Verdadero Negativo (VN), FP o FN.
AlgoritmoElegido	VARCHAR(50)	Nombre del algoritmo que generó la predicción ('RandomForestClassifier').
FechaGeneracionPrediccion	DATETIME	Marca de tiempo de auditoría del despliegue en la base de datos bi_entrega2.

6.2 Página de predicciones en el tablero

Se incorporó al archivo del tablero de Power BI (dashboard/BI-Entrega-2-Equipo507232753.pbix y dashboard/BI-Entrega-3-Equipo507232753.pbix) una tercera página titulada «Página 3: Predicción de Casos con Riesgo de Reliquidación vs. Valores Reales (Modelo Bosque Aleatorio · Entrega 3)». La página se alimenta de la tabla pred_reliquidacion relacionada mediante sus llaves con dim_tiempo, dim_contrato, dim_ubicacion y dim_estado, incluye tres segmentadores interactivos en la parte superior para filtrar por Periodo/Conjunto de datos, por Transportadora (dim_contrato) y por Departamento (dim_ubicacion), presenta cuatro tarjetas KPI de desempeño del modelo y contrasta visualmente los valores reales frente a las predicciones tanto por mes como por operador logístico:

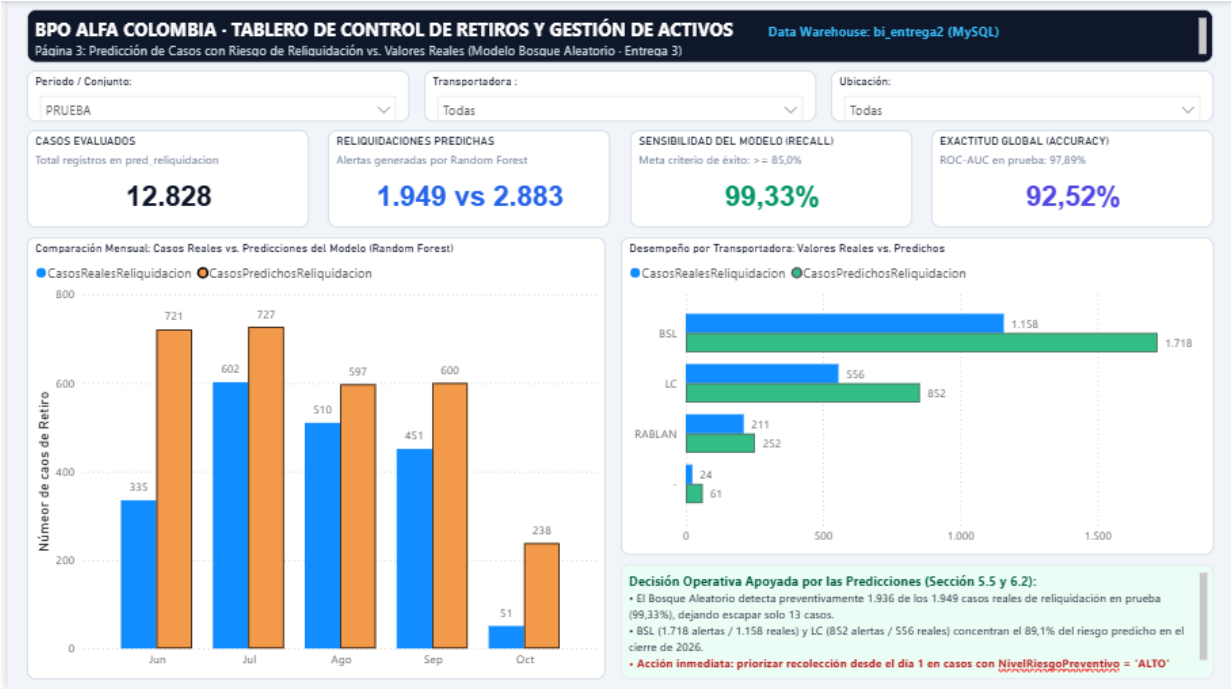


Figura 8. Captura de la Página 3 del tablero de Power BI mostrando las predicciones junto a los valores reales y sus filtros dimensionales.